Telecommunication Customers Churn Prediction

Superviser Learning Classification

Exploratory Data Analysis

1. Berapa banyak perbandingan pelanggan yang melakukan churn dibanding tidak melakukan churn ?

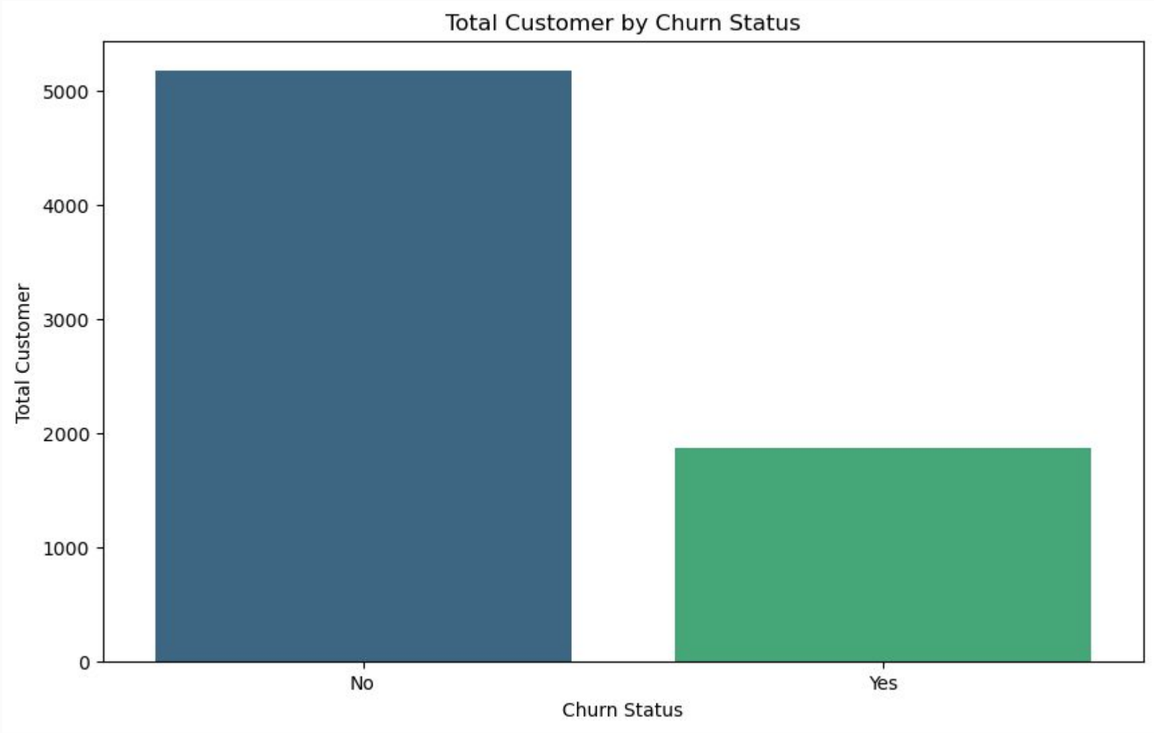

EDA

2. Apakah besarnya MonthlyCharge mempengaruhi pelanggan yang churn ?

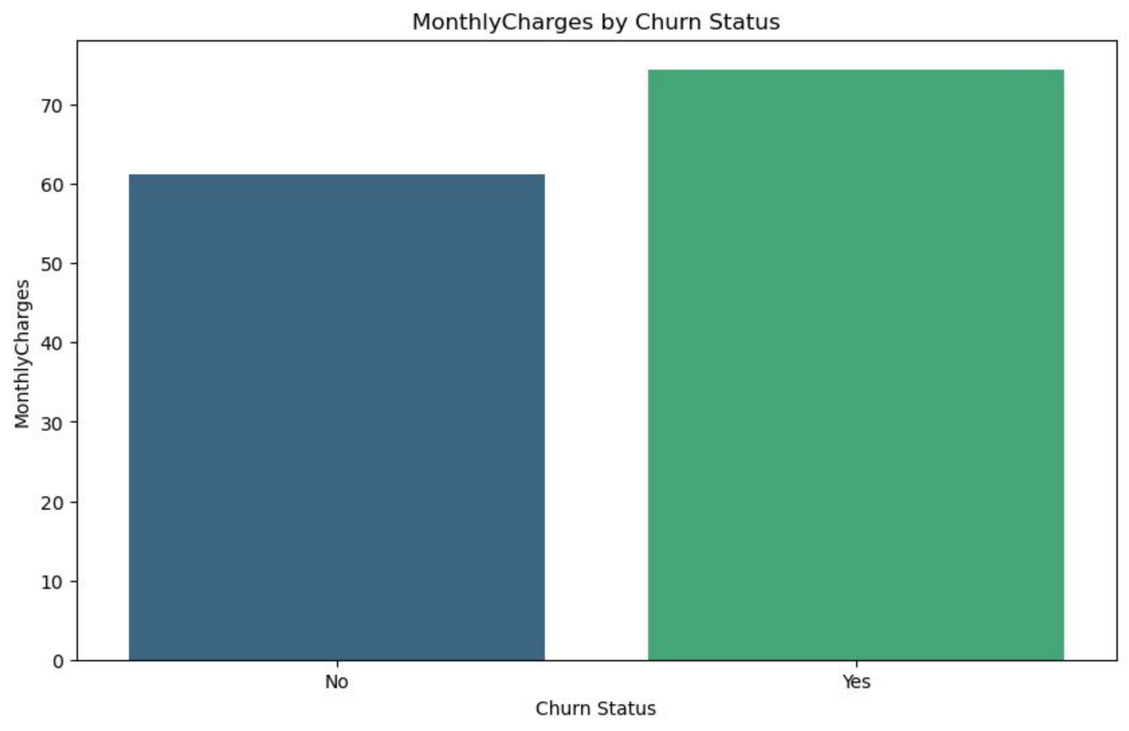

EDA

3. Apakah ada perbedaan tingkat churn antara pelanggan senior citizen dan non-senior citizen?

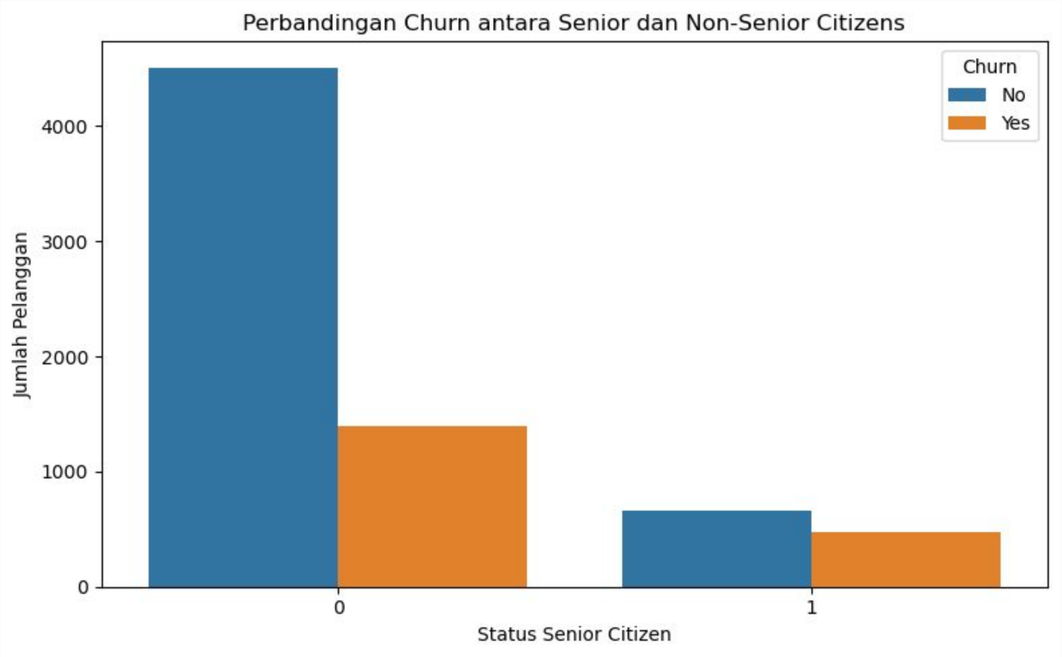

EDA

4. Apakah tingkat tenure mempengaruhi tingkat churn ?

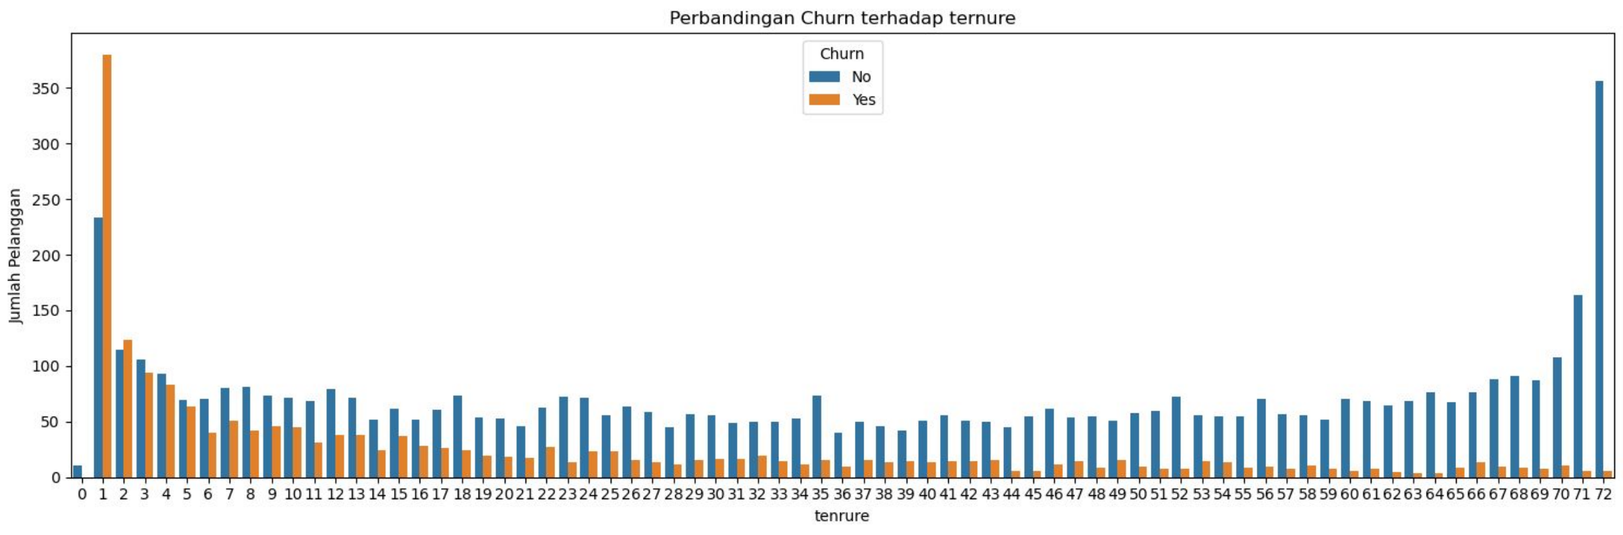

EDA

5. Apakah ada perbedaan tingkat churn antara pelanggan yang menggunakan Internet Service Fiber Optic, DSL , dan yang tidak memakan internet service?

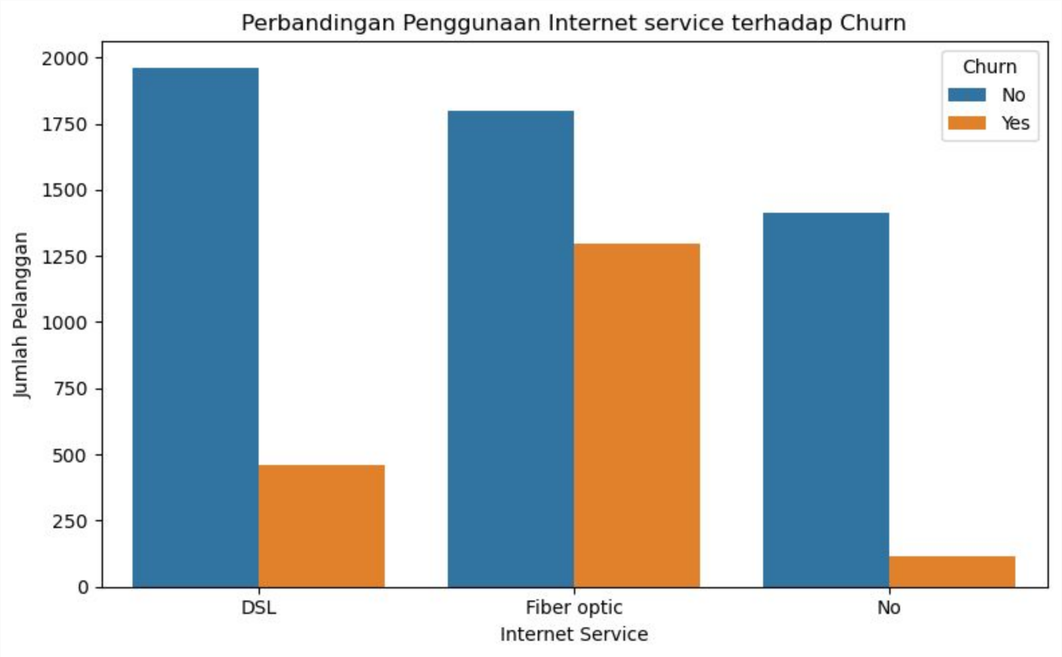

EDA

6. Apakah perbedaan tingkat kontak memperngaruhi tingkat churn ?

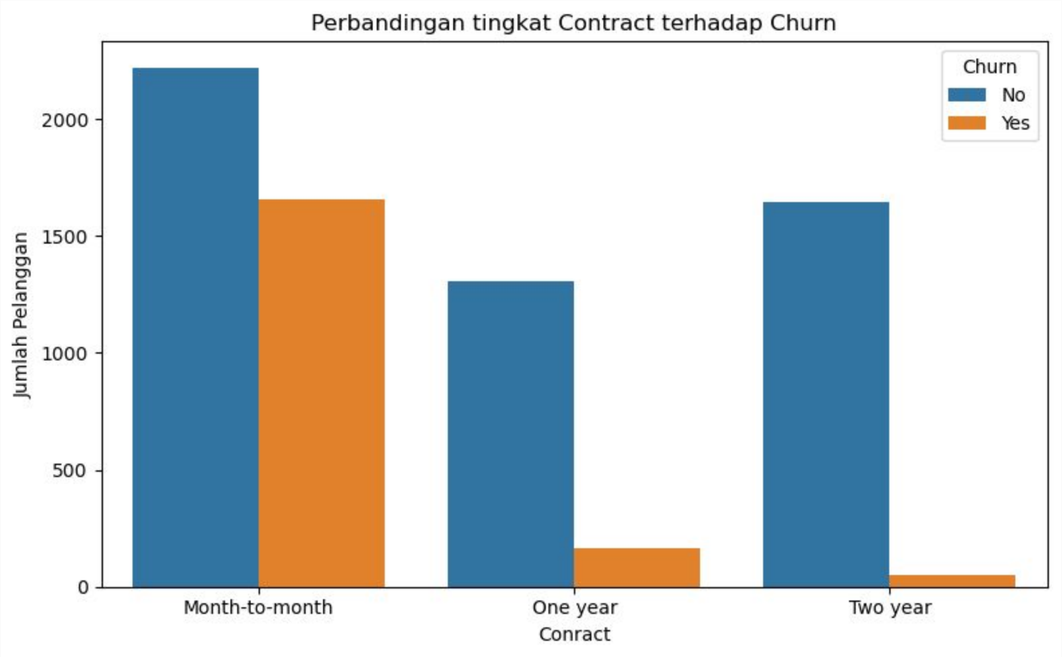

EDA

7.Apakah payment methiod mempengaruhi tingkat churn ?

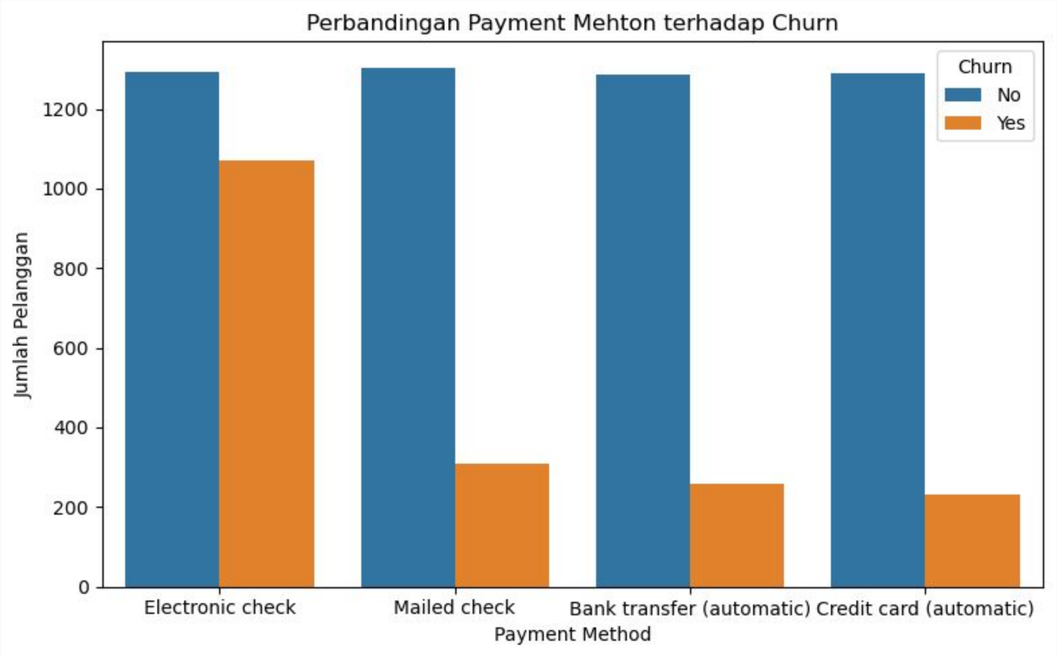

EDA

Descriptive Statistics

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 7043 entries, 0 to 7042
Data columns (total 21 columns):
 #   Column            Non-Null Count  Dtype  
---  ------            --------------  -----  
 0   customerID        7043 non-null   object 
 1   gender            7043 non-null   object 
 2   SeniorCitizen     7043 non-null   int64  
 3   Partner           7043 non-null   object 
 4   Dependents        7043 non-null   object 
 5   tenure            7043 non-null   int64  
 6   PhoneService      7043 non-null   object 
 7   MultipleLines     7043 non-null   object 
 8   InternetService   7043 non-null   object 
 9   OnlineSecurity    7043 non-null   object 
 10  OnlineBackup      7043 non-null   object 
 11  DeviceProtection  7043 non-null   object 
 12  TechSupport       7043 non-null   object 
 13  StreamingTV       7043 non-null   object 
 14  StreamingMovies   7043 non-null   object 
 15  Contract          7043 non-null   object 
 16  PaperlessBilling  7043 non-null   object 
 17  PaymentMethod     7043 non-null   object 
 18  MonthlyCharges    7043 non-null   float64
 19  TotalCharges      7043 non-null   object 
 20  Churn             7043 non-null   object 
dtypes: float64(1), int64(2), object(18)
memory usage: 1.1+ MB
```

	count	mean	std	min	25%	50%	75%	max
SeniorCitizen	7043.0	162.147	368.612	0.00	0.0	0.00	0.00	1.00
tenure	7043.0	32.371.149	24.559.481	0.00	9.0	29.00	55.00	72.00
MonthlyCharges	7043.0	64.761.692	30.090.047	18.25	35.5	70.35	89.85	118.75

- Tidak terdapat nilai null/kosong
- Ada 3 type data yakni float, int, dan object
- terdapat kolom yang tidak sesuai type datanya
- Totalcharge seharusnya bertype float, dan kolom bertipe object nanti saat data preprocesing akan diubah type danya.
- ada 3 kolom yang bertipe numeric, kita fokus pada tenure dan Monhtly charga saja, dimana sebaran datanya cukup beragam dan cendrung terlihat tidak ada ouliet karena jarak mean dan median jaraknya tidak terlalu besar
- untuk kolom bertipe object nanti akan diolah lagi, pada beberapa kolom kategorikal akan dilakukan one hot encoding.

Univarite Analysis

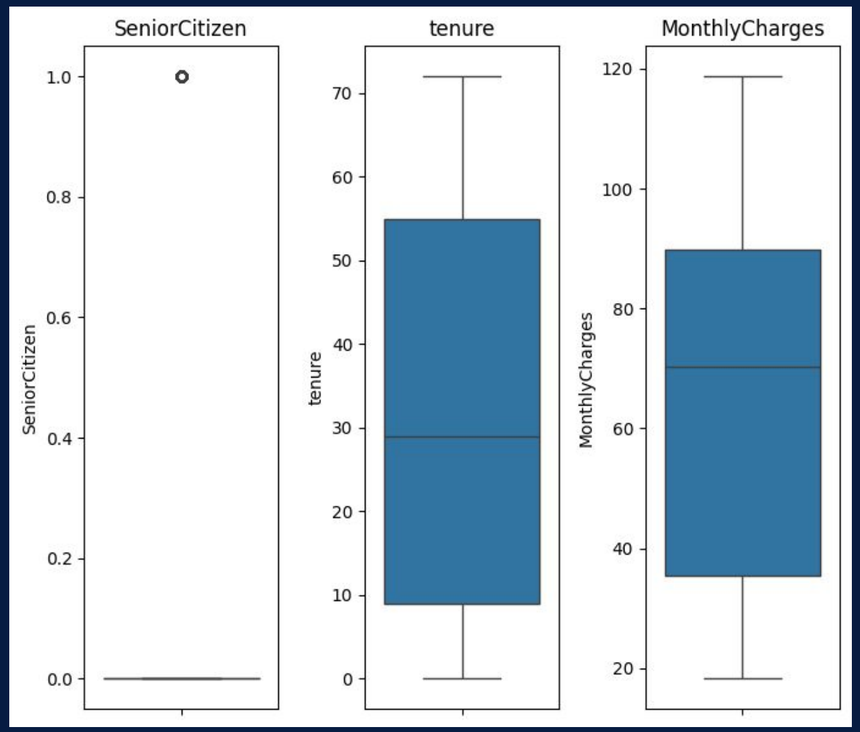

- hanya 3 kolom yang numerik
- Terlihat data tidak ada outlier dan cenderung terdistribusi secara normal

Multivariate Analysis

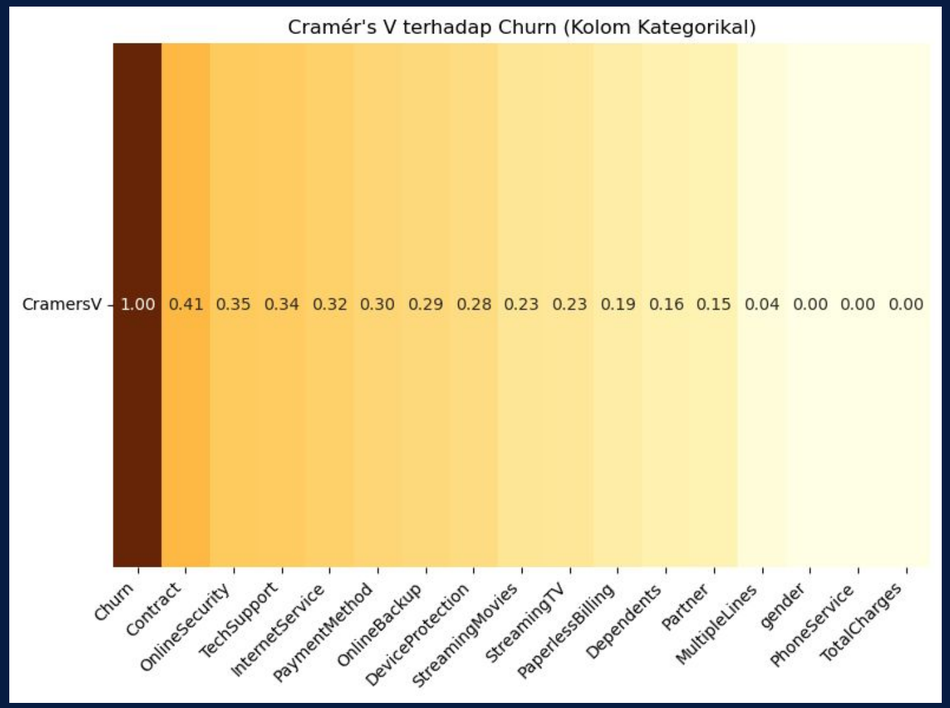

- Melihat hubungan feature kategorikal dengan menggunakan Cramer's V
- Contract, onlineSecurity, dan techSupport memiliki korelari paling tinggi dengan target.
- Dan yang paling rendah adalah gender dan phonservice

Multivariate Analysis

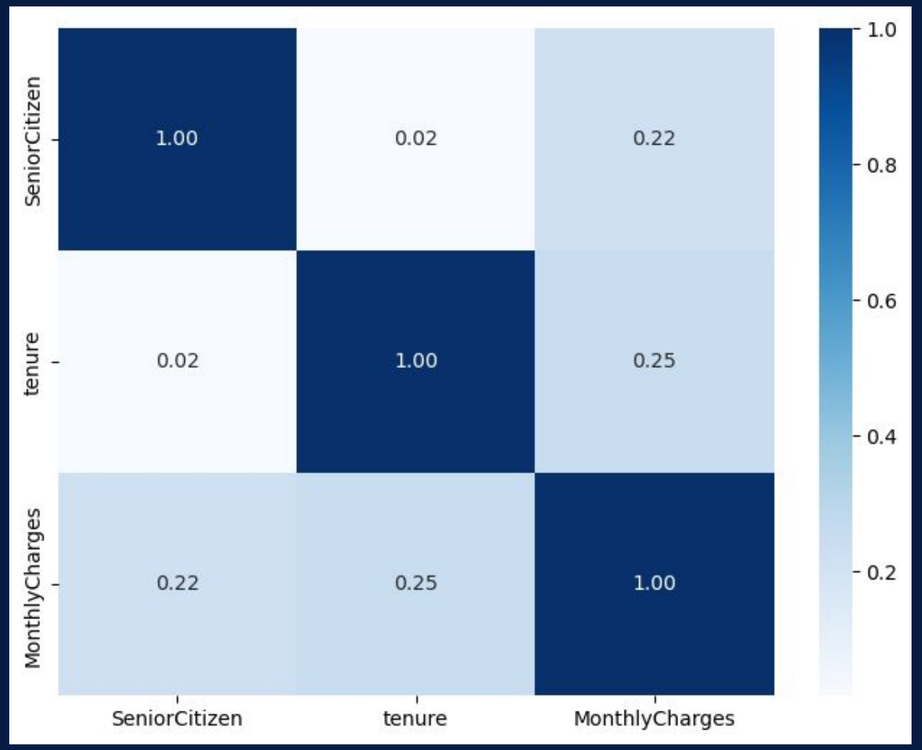

- korelasi antar kolom numeric
- tidak ada nilai korelasi yang redundan, dan bisa di jadikan feature untuk modeling

Multivariate Analysis

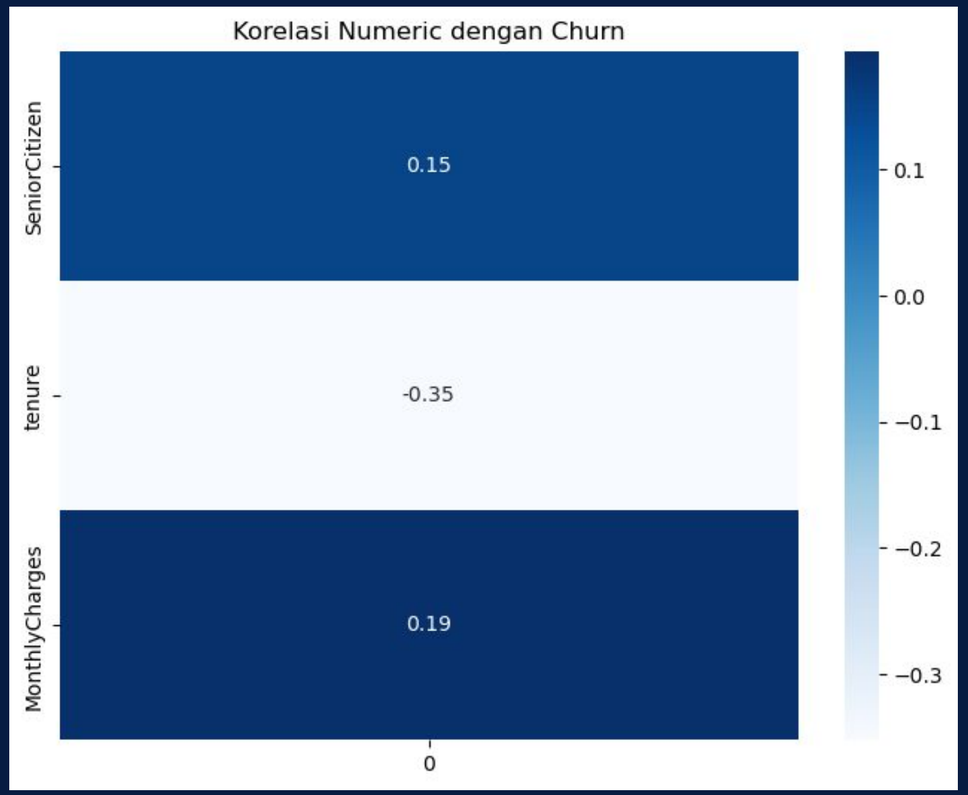

- korelasi kolom numerik dengan taget (Churn)
- nilai korelasi tertinggi adalah feature tenure,
- feature SeniorCitizen dan MothlyCharge koralasi nya cukup untuk dijadikan feature saat modeling

Data Preparation

Handling Missing Value & duplicate data

Missing Value

```
#mengecek missing value
df_cleaned.isnull().sum()
```

✓ 0.0s

SeniorCitizen	0
Partner	0
Dependents	0
tenure	0
PhoneService	0
MultipleLines	0
OnlineSecurity	0
OnlineBackup	0
DeviceProtection	0
TechSupport	0
StreamingTV	0
StreamingMovies	0
PaperlessBilling	0
MonthlyCharges	0
TotalCharges	0
Churn	0
gender_Male	0
InternetService_Fiber optic	0
InternetService_No	0
Contract_One year	0
Contract_Two year	0
PaymentMethod_Credit card (automatic)	0
PaymentMethod_Electronic check	0
PaymentMethod_Mailed check	0

dtype: int64

- Tidak ada data yang missing

Duplicate data

```
# Tampilkan semua baris yang terlibat dalam duplikasi
df_cleaned.duplicated().sum()
```

✓ 0.0s

```
np.int64(0)
```

- Tidak ada data yang duplikat

Data Preparation

Data type adjustment

```python
# Bersihkan spasi di semua kolom object
for col in df_cleaned.select_dtypes(include='object').columns:
    df_cleaned[col] = df_cleaned[col].str.strip()

# Konversi TotalCharges ke numeric
df_cleaned['TotalCharges'] = pd.to_numeric(df_cleaned['TotalCharges'], errors='coerce')

# Isi NaN dengan median secara aman
df_cleaned['TotalCharges'] = df_cleaned['TotalCharges'].fillna(df_cleaned['TotalCharges'].median())

# --- Gabungkan 'No phone service' menjadi 'No' pada MultipleLines ---
df_cleaned['MultipleLines'] = df_cleaned['MultipleLines'].replace({'No phone service': 'No'})

# --- Gabungkan 'No internet service' menjadi 'No' pada kolom terkait ---
internet_cols = [
    'OnlineSecurity', 'OnlineBackup', 'DeviceProtection',
    'TechSupport', 'StreamingTV', 'StreamingMovies'
]
for col in internet_cols:
    df_cleaned[col] = df_cleaned[col].replace({'No internet service': 'No'})

# --- Mapping Yes/No menjadi 1/0 ---
binary_cols = [
    'Partner', 'Dependents', 'PhoneService', 'PaperlessBilling', 'Churn',
    'MultipleLines'
] + internet_cols

for col in binary_cols:
    df_cleaned[col] = df_cleaned[col].map({'Yes': 1, 'No': 0})
```

- Penyesuian type data pada kolom **TotalCharge** yang sebelumnya object ke float dan mengisi nilai kosong dengan median apabila ditemukan nilai Nan/kosong
- karena ada beberapa kolom diisi dengan 3 kategori, seperti colom MultipleLines yang berisi Yes, No, dan No phone service, Maka ‘No phone service’ akan di ubah menjadi No, hingga sisi kolom nya hanya berisi dua kategori Yes dan No saja.
- semua kolom yang berisikan Katergori Yes dan No akan dirubah nilainya menjadi nilai 1 dan 0 saja.

Data Preparation

Feature Engineering

Feature Selection & Tranformation

```
# --- Hapus kolom customerID ---
df_cleaned.drop(['customerID'], axis=1, inplace=True)
```

```
# --- Encode kolom kategorik lainnya dengan One-Hot Encoding ---
multi_class_cols = ['gender', 'InternetService', 'Contract', 'PaymentMethod']
df_cleaned = pd.get_dummies(df_cleaned, columns=multi_class_cols, drop_first=True)
```

```
df_cleaned.isnull().sum()
```

```
df_cleaned.duplicated().sum()
```

✓ 0.0s

```
22
```

```
df_cleaned.drop_duplicates(inplace=True)
```

✓ 0.0s

- semua kolom akan digunakan untuk feature keacuali kolom customerID akan di drop
- melakukan encoding pada kolom kategorikal menggunakan one hot encoding
- dicek lagi apakah setelah encoding ada null value dan ada duplicate, apabila jumlahnya sedikit maka akan didrop

Feature Selection & Tranformation

Code

```
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import  StandardScaler

#Feature scaling untuk numerik
scaler = StandardScaler()
num_cols = ['tenure', 'MonthlyCharges', 'TotalCharges']
df_cleaned[num_cols] = scaler.fit_transform(df_cleaned[num_cols])

#Split fitur dan target
X = df_cleaned.drop('Churn', axis=1)
y = df_cleaned['Churn']

#Train-test split
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)

print("Data siap untuk modeling. Jumlah fitur:", X_train.shape[1])
```

✓ 0.2s

```
Data siap untuk modeling. Jumlah fitur: 23
```

- Melakukan standarisati dengan standarscaler pada kolom **tenure, MontlyCharges, dan TotalCharges**
- Memisahkan feature dan target
- split data menjadi data train dan data tes dengan proposi 20% untuk data test
- jumlah feature keseluruhan menjadi 23 feature

Handling Imbalance

Code

```
#Handling Imbalace
from imblearn.over_sampling import SMOTE

smote = SMOTE(random_state=42)
X_train_bal, y_train_bal = smote.fit_resample(X_train, y_train)

# 8. Cek distribusi target sebelum dan sesudah
print("Sebelum SMOTE:\n", y_train.value_counts(normalize=True))
print("\nSesudah SMOTE:\n", pd.Series(y_train_bal).value_counts(normalize=True))
```

```
Sebelum SMOTE:
 Churn
0    0.735577
1    0.264423
Name: proportion, dtype: float64

Sesudah SMOTE:
 Churn
1    0.5
0    0.5
Name: proportion, dtype: float64
```

- Melakukan balancing pada target didata train menggunakan SMOTE, sehingga didapat data target yang sebelumnya 73% dan 26%, kini menjadi sama 50%-50%

MODELING

MODELING

Code

```
from sklearn.linear_model import LogisticRegression
from sklearn.ensemble import RandomForestClassifier, GradientBoostingClassifier
from xgboost import XGBClassifier
models = [
    ("Logistic Regression", LogisticRegression(max_iter=1000, random_state=42)),
    ("Random Forest", RandomForestClassifier(random_state=42)),
    ("Gradient Boosting", GradientBoostingClassifier(random_state=42)),
    ("XGBoost", XGBClassifier(random_state=42))
]

for name, model in models:

    model.fit(X_train_bal, y_train_bal)
    eval_classification(model, X_train_bal, y_train_bal, model_name=name)
    # plot_confusion_matrix(model, model_name=nam
```

- Melakukan modeling dengan 4 model sebagai perbandingan 1 base model **LogisticRegression**, 3 Esemble model **RandomForestClassifier**, **GradientBoostingClassifier**,**XGBClassifier**

MODEL EVALUATION

Model	Accuracy (Test)	Accuracy (Train)	Precision (Test)	Recall (Test)	Recall (Train)	F1-Score (Test)	ROC AUC (Test)	ROC AUC (Train)	Recall CV Train	Recall CV Test
Logistic Regression	0.76	0.8	0.53	0.71	0.82	0.61	0.83	0.88	0.55	0.55
Random Forest	0.77	1	0.56	0.59	1	0.57	0.81	1	1	0.49
Gradient Boosting	0.77	0.82	0.54	0.74	0.86	0.63	0.84	0.9	0.57	0.53
XGBoost	0.77	0.94	0.55	0.63	0.96	0.59	0.81	0.99	0.85	0.51

MODEL EVALUATION

- Dari ke-4 Model diatas yang akan dipilih adalah **Gradient Boosting** Karena :
  a. LogisticRegression memperoleh nilai evaluasi yang hampir mirip, tetapi Gradient Boosting cerdrung lebih besar nilainya dibanding LogisticRegression.
  b. Niai pada data train dan data test lebih stabil dibanding matrix lain.
  c. Karena fokus kepada konsumen yang churn dan mengurangi False negatif sebanyak mungkin maka dipilih Recall sebagai perhatian utama, dan nilai recall paling tinggi adalah gradientboosting pada data test **0,74** dan data train **0.86.**
  d. pada nilai ROC-AUC paling tinggi dan stabil dibanding yang lain
  e. Nilai Recall Cross Validation menunjukan pengukuran paling stabil jika dibandingkan dengan yang lain, meski nilai nya lebih kecil daripada ketiga model yang lain

Hyperparamer Tuning

```python
# 1. Parameter grid yang lebih sempit & realistis
param_grid = {
    'n_estimators': [100, 150, 200],
    'learning_rate': [0.05, 0.1],
    'max_depth': [3, 4, 5],
    'min_samples_split': [2, 5],
    'min_samples_leaf': [1, 2],
    'subsample': [0.8, 1.0],
    'max_features': ['sqrt', None]
}

# 2. Model dasar
gb_model = GradientBoostingClassifier(random_state=42)

# 3. Cross-validation stratifikasi (penting untuk data imbalance/balance)
skf = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)

# 4. Randomized Search dengan scoring fokus ke 'recall' atau 'f1'
rs_gb = RandomizedSearchCV(
    estimator=gb_model,
    param_distributions=param_grid,
    n_iter=30,  # cukup untuk awal, bisa ditambah
    scoring='f1',  # atau 'recall' jika recall lebih penting
    cv=skf,
    verbose=1,
    random_state=42,
    n_jobs=-1
)

# 5. Fitting ke data yang sudah di-balance
rs_gb.fit(X_train_bal, y_train_bal)

# 6. Evaluasi hasilnya
eval_classification(
    rs_gb,
    X_train_bal,
    y_train_bal,
    model_name="Gradient Boosting (Tuned)"
)
```

```
Fitting 5 folds for each of 30 candidates, totalling 150 fits
========================================
Evaluation Report for: Gradient Boosting (Tuned)
========================================
Accuracy (Test Set): 0.76
Accuracy (Train Set): 0.89
Precision (Test Set): 0.54
Recall (Test Set): 0.65
Recall (Train Set): 0.91
F1-Score (Test Set): 0.59
roc_auc (test-proba): 0.83
roc_auc (train-proba): 0.96
Recall (Crossval Train): 0.72
Recall (Crossval Test):  0.51
```

- Melakukan Tuning Hyperparameter menggukankan metode RandomizedSearchCV
-

Hyperparameter Tuning

Model	Accuracy (Test)	Accuracy (Train)	Precision (Test)	Recall (Test)	Recall (Train)	F1-Score (Test)	ROC AUC (Test)	ROC AUC (Train)	Recall CV Train	Recall CV Test
Gradient Boosting	0.77	0.82	0.54	0.74	0.86	0.63	0.84	0.9	0.57	0.53
Gradient Boosting(tuning)	0.76	0.89	0.54	0.65	0.91	0.59	0.83	0.96	0.72	0.5

- setelah dilakukan tunning banyak metrix menjadi overfitting, salah satunya pada matrix recall awalya 0,74 dan data train 0,86 dan pada hasil tunning nilai nya jadi overfitting 65 dan 91.
- karena nilai hyper lebih kecil dari model sebelumnya maka tidak dilakukan hyper tunning pada model

Shap Plot

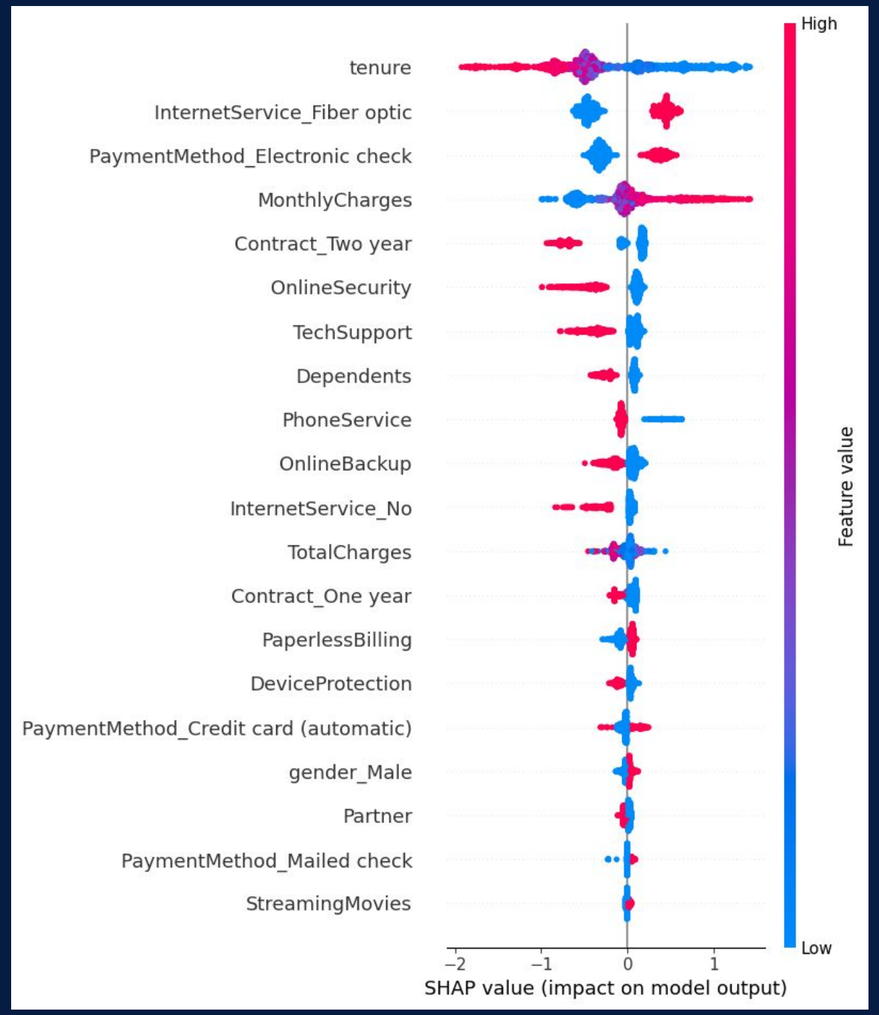

- Feature tenur menjadi feature paling berpengaruh terhadap keputusan model
- Warna biru (tenure rendah) → SHAP value positif → meningkatkan probabilitas churn. Warna merah (tenure tinggi) → SHAP value negatif → menurunkan probabilitas churn.
- feature InternetServicefiberOptik
- Nilai merah (kontrak panjang, misalnya 1-2 tahun) → SHAP value negatif → menurunkan churn. Nilai biru (kontrak bulanan) → SHAP value positif → menaikkan churn.
- feaure MontlyCharge
- Nilai merah (biaya bulanan tinggi) → SHAP value positif → meningkatkan churn. Nilai biru (biaya rendah) → SHAP value negatif → menurunkan churn.

Business Insight

- Pelanggan yang baru bergabung (masa langganan pendek) cenderung lebih berisiko churn. Retensi harus difokuskan pada pelanggan baru di bulan-bulan awal berlangganan.
- Pelanggan dengan kontrak bulanan jauh lebih berpotensi churn. Bisa dilakukan upselling ke kontrak tahunan dengan benefit harga.
- Biaya bulanan yang tinggi bisa menjadi faktor pemicu churn. Strategi diskon atau paket hemat bisa mengurangi risiko ini.

TERIMAKASIH